

Бенчмаркинг обработки скетчей в SBC MarLine

Шахов Андрей

Группа: 25.Б72-мм

Кафедра: системного программирования

Научный руководитель: Гориховский Вячеслав Игоревич

Консультант: Дмитриевцев Алексей Сергеевич, младший инженер по разработке ПО, ООО "КНС ГРУПП"

Номер семестра практики: 3

1. Введение

2. Постановка задачи

Цель работы — разработать воспроизводимую методику бенчмаркинга обработки скетчей в SBC MarLine для оценки стоимости вставки и поиска в различных реализациях индекса при разных размерах базы, а также спроектировать общий интерфейс измерения задержек, применимый ко всем этапам конвейера.

Для достижения цели требуется решить следующие задачи:

1. Определить стадии конвейера, границы отдельных измерений, измеряемые величины и правила агрегации результатов.
2. Подготовить воспроизводимую тестовую нагрузку на архивах версий ядра Linux и зафиксировать параметры построения скетчей.
3. Разработать и проверить сценарии измерения вставки, поиска top- k , полного прохода по запросам и построения индекса.
4. Сравнить линейную, обратную и эвристическую реализации индекса при разных размерах базы; для эвристического поиска оценить качество результатов относительно полного поиска.
5. Спроектировать потокобезопасный интерфейс сбора задержек, пригодный для последовательной и параллельной обработки.
6. Предусмотреть агрегацию статистик и экспорт результатов в машиночитаемом формате.
7. Подготовить тесты и провести экспериментальную оценку точности и накладных расходов измерительного инструмента.

3. Обзор

4. Описание решения

5. Апробация и эксперименты

6. Заключение

Материалы практики и исходный код: https://github.com/kevetka/marline_benchmarks.

Список литературы

- [1] Aronovich L., Asher R., Bachmat E., Bitner H., Hirsch M., Klein S. T. The Design of a Similarity Based Deduplication System. In: Proceedings of SYSTOR 2009. 2009. P. 1–14. DOI: [10.1145/1534530.1534539](https://doi.org/10.1145/1534530.1534539).
- [2] Zhang Y., Xia W., Feng D., Jiang H., Hua Y., Wang Q. Finesse: Fine-Grained Feature Locality Based Fast Resemblance Detection for Post-Deduplication Delta Compression. In: Proceedings of FAST 2019. 2019. P. 121–128. URL: <https://www.usenix.org/conference/fast19/presentation/zhang>.
- [3] Zou X., Deng C., Xia W., Shilane P., Tan H., Zhang H., Wang X. ODESS: Speeding up Resemblance Detection for Redundancy Elimination by Fast Content-Defined Sampling. In: Proceedings of ICDE 2021. 2021. P. 480–491. DOI: [10.1109/ICDE51399.2021.00048](https://doi.org/10.1109/ICDE51399.2021.00048).
- [4] Xia W., Zou X., Jiang H., Zhou Y., Liu C., Feng D., Hua Y., Hu Y., Zhang Y. The Design of Fast Content-Defined Chunking for Data Deduplication-Based Storage Systems. IEEE Transactions on Parallel and Distributed Systems. 2020. Vol. 31, no. 9. P. 2017–2031. DOI: [10.1109/TPDS.2020.2984632](https://doi.org/10.1109/TPDS.2020.2984632).
- [5] Zobel J., Moffat A. Inverted Files for Text Search Engines. ACM Computing Surveys. 2006. Vol. 38, no. 2. Article 6. DOI: [10.1145/1132956.1132959](https://doi.org/10.1145/1132956.1132959).